


FONDO NUOVE COMPETENZE 3. COMPETENZE PER LE INNOVAZIONI



7 Ottobre 2026

Il presente percorso formativo rientra nel progetto E.N.E.L. INNOVATION – Empowerment, New Energies & Leadership presentato dal Gruppo ENEL a valere sull'Avviso FNC 3 – Linea di intervento Sistemi Formativi




Fondo Nuove
Competenze

- *Il Fondo nuove competenze. Competenze per le innovazioni” è un progetto Europa 27, cioè un’operazione di importanza strategica del Programma nazionale Giovani, donne e lavoro 2021-2027, cofinanziato dall’Unione europea. Il Fondo nuove competenze è una misura rivolta alle imprese.*
- *Favorisce l’innovazione e la nuova occupazione: punta ad accrescere le competenze di lavoratrici e lavoratori, per rispondere alle esigenze di digitalizzazione, sostenibilità ambientale, efficientamento energetico.*
- *Il Fondo rimborsa il costo delle ore di lavoro destinate alla frequenza di percorsi di sviluppo delle competenze.*


Enel AI per Human Oversight – Modulo #4

Implementazione pratica

Il nostro percorso insieme



Il nostro percorso insieme



Oggi con voi



Dennis Scopazzi
Deloitte Director
HC Organization & Workforce
Transformation

• Gruppi per Hackaton del 7 ottobre

#	Nome e Cognome	GRUPPO 1
1	ARZUFFI, FRANCESCO	GRUPPO 1
2	MILANI, MARIO	GRUPPO 1
3	COSTI, LOREDANA CINZIA	GRUPPO 1
4	BREVETTI, GERARDO ANTONIO	GRUPPO 1
5	RUDELLO, FABIO	GRUPPO 1
6	MATTIAZZO, ELENA	GRUPPO 1
7	D'AMBROSIO, FRANCESCO	GRUPPO 1
8		
9		
10		
11		
12		

#	Nome e Cognome	GRUPPO 2
1	NATALE, MARCO	GRUPPO 2
2	CORBETTA, LUCA	GRUPPO 2
3	BARBALACO, EMANUELE	GRUPPO 2
4	PALERMITI, EMILIANO	GRUPPO 2
5	MONTUNATO, LUCA	GRUPPO 2
6	SANSONE, MARIA	GRUPPO 2
7	CRETI', FRANCESCO	GRUPPO 2
8		
9		
10		
11		
12		

#	Nome e Cognome	GRUPPO 3
1	MERLINI, GUIDO	GRUPPO 3
2	BARIGAZZI, MARCELLO	GRUPPO 3
3	SALA, FABIO	GRUPPO 3
4	GAZZUOLO, MARCO	GRUPPO 3
5	SCHIROLI, LUCA SISTO	GRUPPO 3
6	TRAMONTANA, GIUSEPPE	GRUPPO 3
7	RIVA, ENRICO FILIPPO	GRUPPO 3
8	CODATO, FABIO	GRUPPO 3
9		
10		
11		
12		

ENERGUARD

AI HUMAN OVERSIGHT HACKATHON

SETTORE ENERGETICO

MANUTENZIONE PREDITTIVA

AI ACT · ART. 14

Una giornata per costruire un sistema AI che un essere umano può davvero controllare

AGENDA



Contesto e sfida

Poichè le infrastrutture energetiche sono considerate asset a “alto rischio”, cosa chiede l'Art. 14, cosa significa “sistema supervisionabile”



Il caso e i materiali

Il sistema EnerGuard, il dataset, le regole del gioco e le consegne



I quattro tier, passo passo

Le istruzioni operative complete di ogni fase: step, tempi, deliverable, errori da evitare



Dashboard, valutazione, test

Le sezioni obbligatorie, i modelli di oversight, i KPI, i sei test della giuria

MANUTENZIONE PREDITTIVA DI ASSET CRITICI



Un sistema AI legge i sensori della rete elettrica e per ogni asset critico produce tre output:



Probabilità di guasto entro 30 giorni

su trasformatori, turbine eoliche, linee AT, cabine primarie



Raccomandazione operativa


nessuna azione · ispezione routine · manutenzione · riduzione carico · ispezione urgente



Confidenza e livello di rischio

quanto il modello è sicuro della predizione e quanto pesa la decisione sul servizio

Il vostro compito: costruire la dashboard con cui un operatore di control room supervisiona, corregge e, ove necessario, “blocca” questo sistema.



LA CHECKLIST DELLA SUPERVISIONE UMANA



Sette requisiti da soddisfare nel design. È la checklist con cui la giuria leggerà il vostro prototipo: tenetevi davanti per tutta la giornata.



Gli operatori possono comprendere capacità e limiti del sistema (model card, documentazione)



Il monitoraggio è continuo durante l'uso, non una fotografia al momento della decisione



Esistono meccanismi per rilevare anomalie e malfunzionamenti (drift, allerte a soglia)



Il design contrasta l'automation bias: mai solo "l'AI dice sì", sempre spiegazioni e incertezza



Gli output sono interpretabili da un operatore non tecnico, non solo un numero



Esiste una capacità reale di override e intervento, non un bottone finto



Esiste una capacità di interruzione del sistema, anche parziale

Ogni sezione della vostra dashboard deve rispondere ad almeno uno di questi punti

NON UN MODELLO: UN SISTEMA SUPERVISIONABILE



Non si valuta se “il modello funziona”. Si valuta se avete costruito un sistema socio-tecnico in cui l'umano esercita un controllo reale, misurabile e tracciato.



CAPIRE

Spiegazioni in linguaggio operativo, incertezza sempre visibile, model card



MONITORARE

Bias per sottogruppo, drift nel tempo, allerte automatiche a soglia



INTERVENIRE

Approva, modifica, rifiuta: con motivazione obbligatoria e blocco reale



FERMARE

Emergency stop totale o parziale, a un click, sempre tracciato

I quattro verbi dell'Art. 14. Sono anche il filo rosso dei sei test finali della giuria.

DAL SENSORE ALLA DECISIONE



Il punto centrale dell'esercizio: tra la raccomandazione dell'AI e l'azione sulla rete ci sono SEMPRE i passaggi 3-4-5. Nessuna azione HITL o HIC può saltare il giudizio umano: la giuria verificherà nel codice che esista un solo punto di esecuzione e che una decisione non approvata non possa raggiungerlo.

IL DATASET CHE RICEVETE



Colonna	Contenuto	Nota operativa
asset_id · tipo_asset	trasformatore, turbina_eolica, linea_AT, cabina_primaria	4 tipologie, criticità diverse
area_geografica	Nord, Centro, Sud, Isole	attenzione: possibile variabile proxy del rischio
eta_anni · temperatura · vibrazione · carico · umidita	condizioni fisiche da sensori	i driver principali del guasto
manutenzioni_5anni · giorni_da_ultima	storia manutentiva dell'asset	non è omogenea tra territori
criticita_utenza	standard · alta · critica (ospedali)	guida il routing HIC
guasto_entro_30gg (target)	guasti REGISTRATI nei sistemi storici	registrato ≠ accaduto

2.400

asset critici, 11 feature, orizzonte 30 giorni

≥ 1

insidia / bias nel dataset nascosta nei dati storici. Trovarla e gestirla vale il 15% del punteggio

Nota di data governance che vale punti: il target è ciò che è stato registrato, non necessariamente ciò che è accaduto. In un'azienda reale i processi di segnalazione guasti non sono omogenei tra territori. Trattate questi dati con il sospetto che riservereste a dati storici veri.



TEAM, TEMPI, CONSEGNE

LOGISTICA



Team da 4-5 persone

mix consigliato: chi codifica, chi ragiona su processo e rischio, chi presenta



10:00 - 18:00

kickoff 30', lavoro sui tier con checkpoint a fine Tier 1 e Tier 2, demo dalle 17:00



Impostazioni tecniche

Python 3.11, scikit-learn, pandas, SHAP, Streamlit; Streamlit/Gradio/React a scelta



Docenti in aula

Consultabili, max 10 minuti a slot

CONSEGNE (ENTRO LE 17:00)



Prototipo funzionante

modello + dashboard con flusso di approvazione end-to-end



Tre documenti

model card (1 pag.) + relazione di impatto (½ pag.) + dichiarazione di oversight



Demo di 5-7 minuti

seguita dai sei test dal vivo della giuria



Codice consegnato

repo o zip: la giuria lo ispeziona durante il test T1

Tutto il toolkit (guida tecnica, indicatori di qualità, starter kit, dataset) vi è condiviso ora, all'inizio della giornata.

UNA GIORNATA, QUATTRO TIER



2h

TIER 1 · Il modello e i suoi limiti

Baseline + metriche disaggregate per area e tipo asset

3h

TIER 2 · Costruire l'oversight

Routing HIC/HITL/HOTL, coda approvazioni, emergency stop

2h

TIER 3 · Spiegabilità e monitoraggio


SHAP in linguaggio operativo, bias & drift monitor, alert

1h

TIER 4 · Demo e revisione critica

Demo 5-7 min + documenti + sei test dal vivo della giuria

RIPARTIZIONE DELLE 8 ORE



■ Tier 1 · Modello ■ Tier 2 · Oversight
■ Tier 3 · Monitoraggio ■ Tier 4 · Demo

Il Tier 2 è il cuore: 3 ore per il flusso di supervisione



IL MODELLO E I SUOI LIMITI

Obiettivo: una baseline funzionante e la prova che sapete guardare oltre l'accuratezza media. Un modello “accurato in media” può nascondere disparità gravi tra territori e tipi di asset.



Da dove partite

train_baseline.py è pronto:
RandomForest, AUC ~0.85 sul
dataset ufficiale. Eseguitelo per primo.



Cosa produce

predizioni.csv con probabilità,
confidenza e predizione per ogni
asset: è l'input della vostra
dashboard.



Cosa NON fare

feature engineering spinto o tuning
ossessivo: da qui in poi i punti si
vincono sull'oversight, non sull'AUC.

Perché si parte da qui: il Tier 1 stabilisce la baseline e introduce da subito il principio chiave della giornata: le metriche aggregate mentono. Tutto ciò che costruirete nei tier successivi (routing, allerte, monitoraggio) poggia sulle metriche disaggregate che produceate adesso.



QUATTRO PASSI, UN DELIVERABLE

1 Eseguite la baseline (15')

python train_baseline.py: verificate AUC, precision, recall. Leggete l'output fino in fondo: le allerte del BiasDetector sono già lì.

2 Scegliete e giustificate la soglia (25')

Cosa costa di più: un falso positivo (ispezione inutile) o un falso negativo (guasto non previsto su una cabina critica)? La soglia deve riflettere questa asimmetria e finire in model card.

3 Metriche disaggregate (40')

Recall, FNR, tasso di selezione per area_geografica e tipo_asset. Annotate ogni gap di recall oltre 15 punti: diventeranno soglie di allerta nel Tier 3.

4 Indagine sui dati (40')

Confrontate i profili di degrado di Sud e Isole con i rispettivi tassi di guasto registrati. Popolazioni simili, tassi molto diversi: scrivete almeno due ipotesi sul perché.

DELIVERABLE TIER 1 · predizioni.csv + mezzo foglio con: metriche per sottogruppo, soglia scelta e perché, anomalie osservate e ipotesi. Checkpoint con i mentori a fine tier.

COSTRUIRE L'OVERSIGHT



Obiettivo: un flusso di approvazione umana reale, end-to-end, non simbolico. È il tier che pesa di più: qui si gioca il criterio da 25% e i tre test-cancello della giuria.



45'

2A · Matrice di routing

chi decide cosa: HIC / HITL / HOTL con soglie giustificate



75'

2B · Coda di approvazione

stati, azioni del revisore, motivazione obbligatoria, SLA



30'

2C · Emergency stop

tre granularità, blocco reale, tracciato nel log



30'

2D · Prima demo interna

il percorso di una decisione, dalla predizione al log

Regola d'oro del Tier 2: nessuna decisione in stato IN_ATTESA può essere eseguita, da nessun percorso del codice. A fine tier dovete saper fare una demo di 60 secondi che lo dimostra.

LA MATRICE DI ROUTING



Condizione	Livello	Perché
Utenza critica coinvolta, o riduzione carico su utenza alta/critica	HIC	Interruzione di fornitura a ospedali: veto umano assoluto, nessuna azione automatica
$P(\text{guasto}) \geq 0.60$ oppure confidenza < 0.80	HITL	Rischio alto o modello incerto: serve giudizio umano prima di agire
Rischio basso + confidenza alta + azione leggera (routine)	HOTL	Il sistema agisce, l'umano monitora via dashboard e può intervenire ex post
Tutti gli altri casi	HITL	Default prudente: nel dubbio, chiedere all'umano

Queste soglie sono il default dello starter kit: cambiatele pure. Ma ogni modifica va motivata nella Dichiarazione di Oversight. La giuria non chiede “quali soglie avete usato”: chiede “perché proprio quelle”, e verifica che il codice faccia ciò che il documento promette (KPI A6: coerenza 100%).



LA CODA DI APPROVAZIONE



Blocco reale

ogni decisione HITL/HIC resta IN_ATTESA e nessun codice la esegue finché un umano non la chiude. Un solo punto di esecuzione nel codice.



Quattro azioni del revisore

approva · modifica l'azione e approva · rifiuta · escalation. Le decisioni HIC non sono mai auto-eseguibili.



Motivazione obbligatoria

minimo 15 caratteri, bloccante. Bonus: rilevare il rubber-stamping (motivazioni fotocopia, revisioni sotto i 10 secondi).



SLA ed escalation

una decisione HITL non revisionata entro lo SLA passa in ESCALATION: mai eseguita in silenzio, mai dimenticata in coda.

COME LO VERIFICA LA GIURIA · Test T1: rifiutiamo una decisione e controlliamo nel codice che l'azione non sia partita. Test T2: proviamo ad approvare con motivazione vuota o “ok”. Entrambi sono cancelli: fallirli azzera il criterio da 25%.

EMERGENCY STOP E PRIMA DEMO



2C · EMERGENCY STOP: REQUISITI

-  Tre granularità: globale · per area geografica · per tipo di asset
-  “Fermare” = blocca le nuove raccomandazioni E rende non eseguibili quelle già in coda nell'ambito
-  Attivazione e disattivazione richiedono motivazione e finiscono nell'audit trail
-  Sempre raggiungibile in ≤ 1 click dalla schermata principale (KPI B4)

Fail tipico da evitare: stop solo globale, o stop che blocca le nuove ma lascia eseguibili quelle già in coda.

2D · LA DEMO DEI 60 SECONDI

A fine Tier 2 il team deve saper mostrare, in un minuto:

1. arriva una raccomandazione ad alto rischio
2. il routing la mette in coda HITL: nulla viene eseguito
3. un operatore la rifiuta, con motivazione
4. il log registra tutto, con orario e autore
5. lo stop d'area blocca anche le decisioni in coda

È la prova generale dei test T1-T3.



SPIEGABILITA', BIAS, MONITORAGGIO

Obiettivo: rendere il sistema trasparente e monitorabile NEL TEMPO, non solo nel momento della singola decisione. È il cuore del monitoraggio continuo richiesto dall'Art. 14.



45'

3A · Spiegabilità

ogni card mostra i 3 fattori principali, in linguaggio da control room, con l'incertezza sempre visibile



45'

3B · Bias & drift monitor

metriche per sottogruppo con allerte, calibrazione per gruppo, drift su finestre temporali, override per area



30'

3C · Alert & audit

soglie che promuovono decisioni a un livello superiore; log filtrabile con integrità verificabile

Il principio: una dashboard senza asse temporale è una fotografia, non un monitoraggio. Il sistema maturo si accorge da solo quando degrada e alza il livello di supervisione (es. tutte le HOTL di un'area diventano HITL finché il gap non rientra).



SPIEGAZIONI DA CONTROL ROOM

X COSÌ NO

```
SHAP value vibrazione_indice = +0.41  
feature_importance eta_anni = 0.28
```

Tecnicamente corretto, operativamente inutile: fallisce il requisito di interpretabilità e il test dei 60 secondi.

✓ COSÌ SÌ

“Vibrazione a 8.2, molto sopra la norma per un trasformatore di quest'età: è il fattore che pesa di più. Contribuiscono 380 giorni senza manutenzione e la temperatura elevata.”

SHAP tradotto in linguaggio operativo: chiunque in control room lo capisce.



Incertezza sempre visibile

mai solo “l'AI dice sì”: mostrate confidenza e casi in cui il modello è in dubbio. È il contrasto all'automation bias richiesto dall'Art. 14(4)(b).



Come farlo in pratica

shap.TreeExplainer sulla baseline, prendete i 3 contributi maggiori e componete la frase con un template. Una feature importance locale ben tradotta è accettabile.

Copertura spiegazioni richiesta: 100% delle decisioni in coda (KPI B1). Una card con solo un numero è una card bocciata.

BIAS, DRIFT, ALERT, AUDIT



Metriche per sottogruppo + allerte

recall, FNR, tasso di selezione per area e tipo asset. Allerta automatica se il gap di recall supera 0.15 (soglia vostra: difendetela).



Drift su finestre temporali

dividete il test set in “settimane”: andamento di accuratezza e confidenza media nel tempo, con soglie di alert visibili.



Alert che agiscono

un'allerta matura non si limita a colorarsi di rosso: promuove le decisioni dell'area a HITL finché il gap non rientra.



Calibrazione per gruppo

probabilità media predetta vs tasso osservato: se divergono in UN solo gruppo, sospettate label bias nei dati storici. È l'indizio chiave dell'insidia nascosta.



Override umano per area

se gli operatori correggono l'AI sistematicamente più spesso in una zona, la dashboard deve farlo notare prima degli auditor.



Audit trail interrogabile

log filtrabile per asset, operatore, periodo + indicatore di integrità della catena di hash sempre visibile in dashboard.

Deliverable Tier 3: dashboard completa nelle quattro aree (coda, matrice, bias & drift, audit) + almeno un alert automatico funzionante.

DEMO E REVISIONE CRITICA



SCALETTA DELLA DEMO (5-7 MINUTI)

1'

Lo scenario

quale problema risolve il vostro sistema e per chi: l'operatore, non il data scientist

3'

Il percorso di UNA decisione

dalla predizione al routing, al giudizio umano con motivazione, fino all'audit trail: fatela vivere dal vivo

2'

Bias, limiti, trade-off

cosa avete scoperto nei dati, cosa avete mitigato, cosa dichiarate di NON aver risolto

Dopo la demo: i sei test dal vivo

La giuria esegue i sei test sul VOSTRO prototipo: override reale, motivazione, stop parziale, comprensibilità, bias nascosto, audit a ritroso.

Consiglio: provate i sei test da soli. Ogni fail scoperto prima della giuria è un fail evitato.

Chiusura della giornata: debrief collettivo con la rivelazione di cosa c'era davvero nei dati.



TRE DOCUMENTI, UNA PAGINA E MEZZA



Model card 1 pagina

scopo del sistema · dati usati
· metriche globali E per
sottogruppo · definizione di
confidenza adottata · limiti
noti · classificazione di rischio
AI Act con motivazione



Relazione di impatto ½ pagina

rischi identificati per sicurezza
e continuità del servizio ·
mitigazioni implementate ·
cosa NON è stato risolto,
dichiarato onestamente



Dichiarazione di oversight ½ pagina

la matrice HIC/HITL/HOTL
adottata · le soglie scelte e la
loro giustificazione · chi
sarebbe provider e chi
deployer nel mondo reale

L'onestà sui limiti vale il 10% del punteggio: un limite dichiarato è un punto guadagnato, un limite scoperto dalla giuria è un punto perso due volte.

LE OTTO SEZIONI DELLA DASHBOARD



Le otto sezioni obbligatorie: ognuna aggancia un requisito normativo. Specifiche complete nel documento “Indicatori di qualità della dashboard”.

HIC · HITL · HOTL



HIC

Human-in-Command

Veto umano assoluto: l'AI propone, solo l'umano dispone. Nessuna esecuzione automatica, mai.

Quando: Interruzioni di fornitura a utenze critiche: ospedali, infrastrutture essenziali

HITL

Human-in-the-Loop

Nessuna esecuzione senza approvazione umana preventiva e motivata.

Quando: Rischio alto o confidenza bassa: manutenzioni su asset critici, casi incerti

HOTL

Human-on-the-Loop

Il sistema agisce, l'umano monitora via dashboard e può intervenire ex post.

Quando: Basso rischio + alta confidenza: ispezioni di routine su asset non critici

Non basta dichiararli: la tripartizione va implementata nel routing a soglie (step 2A), e ogni soglia va giustificata.

IL MOCKUP ENERGUARD



ENERGUARD
 SUPERVISIONE UMANA · MANUTENZIONE PREDITTIVA RETE

7
 IN ATTESA DI
 REVISIONE

2:41
 TEMPO
 MEDIANO
 REVISIONE

18%
 TASSO
 OVERRIDE
 (24H)

100%
 COPERTURA
 SPIEGAZIONI

1
 ALLERTE
 FAIRNESS
 ATTIVE

OK
 INTEGRITÀ
 AUDIT TRAIL

INTERRUZIONE ART.
 14(4)(F)

Ambito: GLOBALE

STOP

CODA DECISIONI · IN ATTESA DI GIUDIZIO UMANO
 ART. 14(4)(d)(e)

AST-01847
HIC · VETO UMANO

Cabina primaria · Sud · Utente critica (presidio ospedaliero) · in coda da 4 min

P(guasto 30gg) **0.81** Confidenza **0.81** Azione proposta **riduci carico**

Perché il sistema lo raccomanda: vibrazione a 8.9, molto oltre la norma per una cabina di 27 anni; 402 giorni dall'ultima manutenzione; temperatura di esercizio 51 °C in crescita.

⚠ Ridurre il carico impatterebbe un'utenza ospedaliera: il sistema NON può agire da solo. La decisione è interamente sua.

Motivazione obbligatoria (min 15 caratteri)...

Approva Modifica azione Rifiuta

0 / 15 caratteri · I pulsanti si sbloccano con la motivazione

AST-00293
HITL · SERVE APPROVAZIONE

Trasformatore · Isole · Utente standard · in coda da 11 min

P(guasto 30gg) **0.64** Confidenza **0.64 · bassa** Azione proposta **ispezione urgente**

Perché il sistema lo raccomanda: 31 anni di età (fattore principale), una sola manutenzione in 5 anni, carico medio 88%.

⚠ Il modello è incerto su questo caso: i sensori di vibrazione danno valori nella norma, in contrasto con gli altri fattori. Valutare un sopralluogo prima di programmare.

Motivazione obbligatoria (min 15 caratteri)...

Approva Modifica azione Rifiuta

0 / 15 caratteri

+ 5 decisioni in coda, ordinate per rischio × urgenza · 12 azioni HOTL auto-eseguite oggi (basso rischio, alta confidenza) — vedi log

MATRICE CONFIDENZA × RISCHIO · CHI DECIDE
 ART. 14(4)(b)

HIC — SOLO L'UMANO DECIDE

HITL — APPROVAZIONE UMANA

HOTL — AUTO + MONITO

rischio 0.60

conf 0.80

Confidenza del modello →

● HIC (2) ● HITL (5) ■ HOTL auto-eseguite (12)

Le soglie di routing sono dichiarate nella Dichiarazione di Oversight e applicate dal codice (KPI A6: coerenza 100%). L'utenza critica forza HIC a prescindere dalla posizione nella matrice.

FAIRNESS & DRIFT MONITOR
 ART. 10 · 14(4)(c)

AREA	RECALL	FNR	CALIBRAZIONE Δ	OVERRIDE	STATO
Isole	0.79	0.21	+0.01	12%	OK
Sud	0.47	0.53	+0.02*	31%	Indagare
Centro	0.38	0.62	-0.01	17%	Gap recall
Nord	0.29	0.71	-0.03	9%	Gap 0.50

Allerta attiva: gli operatori correggono l'AI nel Sud 2,4 volte più spesso della media (KPI C3) e i profili di degrado Sud/Isole sono simili a fronte di tassi di guasto storici molto diversi. Sospetta sotto-segnalazione storica dei guasti (label bias). **Mitigazione in corso:** tutte le decisioni HOTL dell'area Sud sono promosse a HITL finché l'indagine sui dati non si chiude.

* La calibrazione "perfetta" del Sud è calcolata sulle label registrate: se le label sono incomplete, la coerenza col dato storico non è una garanzia. Drift ultimo trimestre: accuratezza -2 punti, entro soglia.

Emergency stop
sempre a un click, con
selettore di ambito

Spiegazioni da control
room, non da data
scientist

Allerta fairness già
implementata sui dati
che ricevete

Audit trail con catena di
hash verificabile a
schermo

Riferimento di livello “maturo”, incluso nel toolkit come file HTML navigabile: potete discostarvene, ma ogni scelta va difesa davanti alla giuria.

DATASET E STARTER KIT



NELLO STARTER KIT



energuard_dataset.csv 2.400 asset, 11 feature,
target a 30 giorni



train_baseline.py RandomForest pronto + metriche
disaggregate



oversight_manager.py routing HIC/HITL/HOTL,
coda, emergency stop



bias_detector.py metriche per sottogruppo + allerte
automatiche



audit_logger.py log append-only con catena di hash



app.py scheletro Streamlit con le sezioni obbligatorie

I DUE DOCUMENTI DA LEGGERE PRIMA DI SCRIVERE CODICE

Indicatori di qualità della dashboard


i 16 KPI con target, i sei test della giuria e la
rubrica di valutazione. Costruire sapendo come
si viene misurati È parte dell'esercizio.

Guida tecnica dei partecipanti

il dettaglio operativo di ogni tier, il dizionario del
dataset, i riferimenti normativi minimi e le
domande guida per l'indagine sui dati.

AUC della baseline: ~0.85. Non è lì che si vince: da quel punto in poi contano solo oversight, trasparenza e tracciabilità.

CRITERI E PESI DELLA GIURIA



Il criterio che pesa di più

Supervisione umana effettiva: 25%. Un pulsante “approva” che non blocca nulla vale zero, e fallire un test-cancello azzerava l'intero criterio.

Come si vince

Supervisione + spiegabilità + fairness valgono insieme il 60%. Il modello “migliore” conta per il 20: la giornata si vince sul controllo, non sull'accuratezza.

I KPI CHE LA DASHBOARD DEVE ESPORRE



KPI	Cosa misura	Target	Segnale d'allarme
A1 · Auto-esecuzioni improprie	decisioni HIC/HITL eseguite senza revisione	0, assoluto	qualsiasi valore > 0 è squalificante
A2 · Tasso di override	rifiutate + modificate / revisionate	5% - 40%	~0% = rubber-stamping · >60% = soglie sbagliate
A4 · Rubber-stamping	motivazioni < 30 caratteri o duplicate	< 10%	la motivazione è diventata un rito
B1 · Copertura spiegazioni	card con spiegazione in linguaggio naturale	100%	card con solo un numero di probabilità
B4 · Distanza dal gesto critico	click per spiegazione / override / stop	≤2 · ≤2 · ≤1	emergency stop dentro un sottomenu
C1 · Gap di recall tra gruppi	max-min recall per area e tipo asset	esposto; allerta > 0.15	calcolato ma non mostrato all'operatore
D2 · Integrità del log	catena di hash verificabile da dashboard	integra	log modificabile senza che nulla se ne accorga

Questi KPI vanno esposti NELLA dashboard stessa: un sistema di oversight che non misura la propria supervisione non è supervisionabile. Lista completa (16 KPI) nel documento Indicatori.

SEI PROVE, TRE CANCELLI



T1 **Override reale · CANCELLO**
rifiutiamo una decisione: l'azione NON deve partire, e ce lo dimostrate nel codice

T2 **Motivazione · CANCELLO**
approvare con motivazione vuota o "ok" deve essere impossibile

T3 **Stop parziale · CANCELLO**
"fermate le linee AT del Sud, il resto continua": un click, tracciato nel log

T4 **60 secondi**
un giurato non tecnico deve capire una decisione usando solo lo schermo

T5 **Bias nascosto**
cosa avete scoperto sui dati storici? Misurato, indagato, mitigato?

T6 **Audit a ritroso**
ricostruite in un minuto chi ha deciso cosa, quando e perché

Fallire un cancello (T1-T3) azzerava il criterio da 25%: un oversight che non blocca, non motiva o non si ferma è simbolico per definizione.

GLI ERRORI CHE FANNO PERDERE PUNTI



Solo il modello, niente dashboard

manca l'oggetto centrale dell'esercizio: il modello è il motore, non il prodotto



Il pulsante “approva” finto

aggiorna l'interfaccia ma l'azione era già partita: oversight simbolico, T1 fallito



Metriche solo aggregate

nessuna disaggregazione per sottogruppo = bias invisibile = T5 fallito



Spiegazioni da data scientist

SHAP value grezzi incomprensibili a un operatore: T4 fallito



Niente audit trail

nessuna tracciabilità = nessuna accountability = T6 fallito



Tutto il tempo sull'AUC

ore di tuning per +0.02 di AUC che valgono zero punti: gestite il tempo sui tier

Sono i cinque errori storici di questo esercizio, più il ladro di tempo. Ve li diciamo adesso perché nessuno li commetta alle 16:00.

OBIETTIVO

LA MISSIONE DELLA GIORNATA

**UN UMANO DEVE POTER
CAPIRE · MONITORARE
INTERVENIRE · FERMARE
IL SISTEMA CHE COSTRUIRETE**

In un'infrastruttura critica, un sistema accuratissimo ma non supervisionabile è un sistema non conforme e pericoloso.

FORMATE I TEAM · SI PARTE ALLE 10:30

Let's talk!



Q&A





Fondo Nuove Competenze